



Soundscapes Analysis

Progetto di Machine Learning



Data Science e Gestione dell'Innovazione

Bruno Asia
Giliberti Felicità
Langelotti Pasquale
Rega Giuseppe

PROJECT GOALS:

Cosa vogliamo ottenere?



Applicare un modello AI di Anomaly Detection per voci umane

Abbiamo utilizzato tecniche di deep learning per addestrare modelli in grado di distinguere automaticamente la presenza di voci umane all'interno dell'audio.

Il modello elabora un file audio in ingresso e genera un avviso quando individua la presenza di voce umana.



Separare la voce umana da audio contenenti background

Abbiamo affrontato il problema della separazione audio, in cui un segnale misto contiene sia parlato che suoni ambientali come traffico, vento, passi o altri disturbi acustici.

L'obiettivo è isolare la voce per renderla più chiara e analizzabile.

APPLICAZIONI REALI

Perché non possiamo ignorare l'importanza del riconoscimento vocale?

Il riconoscimento vocale riveste un'importanza significativa nell'attuale realtà tecnologica. Le sue applicazioni sono svariate, ad esempio:

- Miglioramento qualità audio in ambienti rumorosi (call, conferenze)

La separazione vocale consente di filtrare i disturbi di fondo durante videoconferenze o registrazioni in ambienti non controllati.

- Supporto a sistemi di riconoscimento vocale

Molti sistemi di speech-to-text faticano con audio sporchi.

- Analisi automatica di registrazioni ambientali

In scenari reali, l'audio catturato da microfoni ambientali è quasi sempre un mix di suoni.

- Contesti di sorveglianza acustica o emergenza

In ambienti pubblici o industriali, rilevare voci in mezzo al rumore può essere cruciale.



WAVEFORM (FORMA D'ONDA)

Cos'è?



La **waveform** è la rappresentazione grafica **nel dominio del tempo** di un segnale audio. Mostra come **l'ampiezza del suono varia nel tempo**.

Esempi d'uso:

Rilevamento dei silenzi

Segmentazione audio

Analisi dell'intensità o energia del segnale

Vantaggi principali

- **Intuitiva**: mostra visivamente la presenza di suoni, silenzi e transizioni.

- **Temporalmente precisa**: utile per analizzare eventi sonori in momenti esatti (es. picchi, impulsi, attacchi).

- **Leggera da calcolare**: non richiede trasformazioni complesse come lo spettrogramma.

- **Base per il pre-processing**: fondamentale per operazioni come normalizzazione, slicing, rimozione del silenzio.

- **Compatibile con modelli raw audio**: alcuni modelli deep learning possono lavorare direttamente con waveform (es. WaveNet, Wave-U-Net).

Svantaggi principali

Difficile da elaborare per i modelli: **alta dimensionalità** e **rumore** elevato.

Richiede reti **più profonde e complesse** per ottenere buoni risultati.


Meno interpretabile visivamente: è difficile "vedere" la voce nel waveform.

DATA PREPARATION

La base del progetto: i dati

Abbiamo selezionato dataset pubblici di **voce** (Common Voice) e di **background ambientale** (ESC-50, UrbanSound8K), filtrando i campioni tra 5 e 9 secondi per garantire uniformità.

I file sono organizzati in cartelle Event e Background.



FASI DEL PROGETTO

1. Raccolta Dati

Scaricati dataset vocali e i background ambientali da fonti pubbliche

2. Suddivisione Dataset

I file contenuti nelle cartelle “Event” e “Background” sono stati suddivisi in Training (80%), Validation (10%) e Test (10%)

3. Creazione dei Mix Audio

Ogni traccia vocale è stata mescolata con uno o più background per simulare situazioni reali

4. Generazione Dataset Mixato

Creato un dataset contenente mixture = voce + background

5. Salvataggio Percorsi in CSV

I percorsi dei file sono stati scritti in tre file train.csv, test.csv, validation.csv separati, con all'interno 3 colonne, background, voice e mixture per facilitare il caricamento

Task 1: Anomaly Detection

Modello di Riconoscimento Voce/Background (Non Supervisionato con U-Net)


Obiettivo Principale

- **Rilevamento di anomalie sonore** in tempo reale
- **Approccio non supervisionato**: il modello apprende il profilo acustico da tracce audio background
- **Il modello quindi riconosce anomalie**

Caratteristiche

- **Non supervisionato**: no labeling anomalie
- **Temporal modeling**: BiLSTM cattura pattern temporali
- **Multi-scale**: 5 livelli per pattern diversi
- Parametri totali: 11 530 430

Wave-U-NET 1D AnomalyDetectorUNet



Preprocessing Audio & Ottimizzazione

Preprocessing Audio

- **Caricamento dati** con *librosa* (supporta WAV, MP3, ecc.).
- **Standardizzazione:**
 - Mono → un unico canale audio.
 - Ricampionamento a **16 kHz** (consistenza temporale).
- **Gestione durata:** padding o truncation per uniformare la lunghezza dei campioni.
- **Normalizzazione ampiezza:** valori scalati in $[-1, 1]$ per stabilità numerica.
- **Conversione in tensori PyTorch** per l'addestramento.



Ottimizzazioni

- **Lazy loading** → efficienza di memoria.
- **Data augmentation** → migliora robustezza e generalizzazione del modello.
- **Normalizzazione RMS:** tecnica di normalizzazione dell'energia → consistenza degli input e training più stabile.

Logica di Apprendimento

Fasi:


1. **Input:** solo audio di background
2. **Training:** il modello impara le caratteristiche del rumore e rileva ciò che è diverso
3. **Inferenza:** rileva automaticamente:
 - **Voice Component** = non-background → Anomalia
 - **Background Component** = riconosciuto come rumore



Training Loop

Strategia:

- **Forward pass** → il modello elabora e produce predizioni
- **Loss** → misura l'errore
 - **L1 Loss**: misura la differenza media assoluta tra le predizioni del modello e i valori reali
 - Best epoca: 17 con Val Loss 0.00021
- **Backpropagation** → aggiorna i pesi per ridurre l'errore
- **Validation** → controlla che l'apprendimento sia stabile e generalizzabile





Monitoring:

- **Checkpoint modelli migliori** → salva pesi del modello migliore (non necessariamente dell'ultima epoca)
- **Logging metriche**: registrazione di parametri durante training/validation → permette di diagnosticare problemi
- **Reconstruction Quality**: misura quanto l'audio ricostruito riconosce correttamente l'input originale
→ assicura fedeltà al segnale originale

RISULTATI DEL MODELLO: Test

Procedura di Inferenza	Risultati dell'analisi sugli errori (anomali)	Interpretazione
• Applicazione del modello su file mai visti in addestramento. • Output → alert in caso di riconoscimento voce umana • Analisi degli errori campione per campione.	• File processati con successo: 15.643 • Errore Medio: 0.0307 • Deviazione Standard: 0.0279 • Errore Minimo: 0.0000 • Errore Massimo: 0.1746	• La maggior parte dei campioni ha errori contenuti e stabili (bassa varianza). • Il modello riesce quindi a generalizzare bene, ma richiede attenzione su casi limite.

Esempio Inferenza Anomaly Detection



Task 2: WaveMod: Architettura per Separazione Audio (Modello Supervisionato)


L'architettura a **separazione audio** è un approccio progettuale che gestisce in modo distinto i diversi flussi sonori all'interno di un sistema (es. voce, musica, effetti, rumori di fondo).

L'**obiettivo** è **isolare e controllare ogni sorgente sonora** per garantire:

- **Maggiore chiarezza:** separazione tra voce e rumore.
- **Flessibilità:** possibilità di trattare ogni canale con algoritmi specifici (riduzione del rumore, beamforming, equalizzazione).
- **Scalabilità:** integrazione in sistemi complessi come videoconferenze, assistenti vocali, sistemi automotive.
- **Esperienza utente ottimale:** audio più naturale e comprensibile.

In pratica, questa architettura permette di **migliorare l'elaborazione del parlato** e la **qualità complessiva dell'audio**, rendendo più efficace l'interazione uomo-macchina.

Wave-U-Net 1D AudioSeparation



TRAINING: ARCHITETTURA, LOSS E OTTIMIZZAZIONE

01

● Modello:

- Encoder - Decoder 5 livelli
- BiLSTM centrali
- Skip Connections
- Parametri totali: 10,892,246

02

● Loss (L1)

- Calcolo basato sul valore assoluto
- Robustezza agli outlier

03

● Optimizer (AdamW)

- Migliore generalizzazione
- Riduzione overfitting
- Regolarizzazione efficace

TRAINING VS VALIDATION LOSS




VALUTAZIONE FINALE

DALLE METRICHE AI RISULTATI SUL TEST SET

Metriche Utilizzate	Procedura di valutazione	Risultati principali
• SDR (Signal-to-Distortion Ratio): qualità della separazione (più alto = meglio). • SNR (Signal-to-Noise Ratio): rapporto segnale/rumore. • Correlazione di Pearson: similarità tra forma d'onda predetta e reale. • MAE / MSE: errore assoluto e quadratico medio.	• Iterazione sui batch mai visti in addestramento • Per ogni campione: → Output: evento + background → Calcolo metriche • Risultato finale: media $\pm$ deviazione standard	• Errore Medio: molto basso • Deviazione Standard: contenuta, segno di buona stabilità • MSE: ridotto (≈ 0.00168 event; ≈ 0.00162 background) • MAE: ridotto (≈ 0.0170 event; ≈ 0.0170 background) • SNR: alto, quindi buon rapporto segnale/rumore (event ≈ 14.27; background ≈ 6.03) • SDR (event): 14.27 • SDR (background): 6.03 • Correlazione (event): 0.94 • Correlazione (background): 0.82

RISULTATI DEL MODELLO DI SEPARAZIONE AUDIO WAVEFORM



RISULTATI DEL MODELLO DI SEPARAZIONE AUDIO WAVEFORM



RISULTATI DEL MODELLO DI SEPARAZIONE WHISPER

```
▼ original_transcription:
  ▼ text:                "rispettivamente gli anni della spedizione dei mille e della proclamazione del Regno d'Italia."
    language:            "it"
    segments:            1
  ▼ processing_info:
    duration:            8.18
    segments_count:      1
▼ processed_transcription:
  ▼ text:                "rispettivamente gli anni della spedizione dei mille e della proclamazione del Regno d'Italia."
    language:            "it"
    segments:            1
```

```
▼ quality_assessment:
  overall_score:         10
  quality_level:         "ECCELLENTE"
  transcription_fidelity: "PERFETTA"
  audio_quality_inference: "ALTA"
▼ linguistic_analysis:
  detected_language:     "it"
  complex_words_preserved: 4
  punctuation_fidelity:  0
  capitalization_consistency: 1
▼ recommendations:
  ▼ 0:                   "✅ Trascrizioni identiche - processing audio ottimale"
  ▼ 1:                   "🚀 Modello pronto per deployment in produzione"
▼ detailed_comparison:
```

Grazie dell'attenzione

